

웨어러블 라이프로그를 이용한 치매 예측

- 일상생활능력의 저하를 중심으로 -

Prediction of Dementia Using Wearable Lifelog

- Focusing on the Deterioration of Activities of Daily Living -

아주대학교 e 비즈니스학과

201823871

박 지 헌

Jiheon788@ajou.ac.kr

제출일: 2022 년 06 월 16 일

목차

1. 서론	2
1.1 문제정의 및 동기	2
1.2 문제해결방안 제시	2
2. 본론	3
2.1 데이터 수집 및 EDA	3
2.2 Modeling 및 성능비교	3
2.3 변수중요도 및 변수선택	4
3. 결론	4
3.1 분석 및 해석	4
3.2 프로젝트를 통해 얻은 교훈	5
참고문헌	5
부록	5

1. 서론

1.1 문제정의 및 동기

오늘날, 고령화 사회로 진입하면서 치매 발병률이 증가하고 있다. 보건복지부에 따르면 지금도 15분마다 1명씩 새로운 치매 환자가 발생하고 있고, 2010년 50여만명인 치매 환자 수는 향후 20년마다 두배씩 증가해 2030년에는 100여만명, 2050년에는 200여만명에 이를 것으로 예상되고 있다. 치매 환자를 돌보는데 들어가는 시간과 비용적인 측면에서 생각해보면, 이는 상당한 경제적인 손실과 위협을 초래한다. 치매의 초기 단계에는 사소한 기억력 장애, 시간, 장소 등을 잊는 지남력 장애 등의 현상을 보인다. 그러나 대개 환자나 가족들이 이러한 과정을 단순히 노화 과정으로 오인하거나 치매는 치료할 수 없다는 인식 때문에 치매가 상당히 진행되고 병원을 찾는 경우가 많다. 하지만 초기에 치매를 발견하고 치료를 시작하면 증상악화를 지연시켜 가족들이 치매 환자를 돌보며 쓰게 되는 시간과 비용을 더 줄일 수 있다. 치매 초기 단계부터 약물치료 시, 5년 후 요양시설 입소율은 55% 감소하며 8년간 약 7,800시간과 약 6,400만 원을 절약할 수 있는 것으로 나타났다[1]. 이와 같이 치매는 조기 발견하여 치료하는 것이 중요하며, 이미 치매가 진행된 환자라도 적절한 평가와 치료를 통해 상당히 호전될 수 있다.

1.2 문제해결방안 제시

치매의 진단은 첫째, 환자의 인지기능 평가, 둘째, 인지기능저하로 인하여 유의한 일상생활능력(activities of daily living, ADL)의 저하, 셋째, 치매에서 흔하게 동반되는 이상행동, 넷째, 치매의 중증도를 평가, 다섯째, 치매의 원인 질환을 찾기 위한 검사, 총 다섯가지를 평가해야 한다[2]. DSM-IV에서는 치매의 진단을 위해서 인지장애 뿐 아니라 이로

인한 일상생활이나 사회생활에서의 유의한 장애를 필요조건으로 하고 있다[3]. 그러므로 환자의 인지기능이 떨어져 있으나 ADL에 유의한 지장이 없다면 치매보다는 나이에 따른 양성건망증이나 경도인지장애 또는 기타 다른 원인의 가능성을 고려해야 한다.[4] 기존 진단법 중 ADL 저하와 이상행동은 문진, 설문지나 보호자와의 면담을 통하여 평가한다. 본프로젝트에서 이러한 정보를 웨어러블 기기를 통해 수집한 라이프로그로 측정하여 평가 가능하다는 가설을 세워 AI 알고리즘으로 분석해 치매를 예측하여 예방 및 조기 발견할 수 있는 모델을 만들고, 변수중요도와 모델의 성능을 확인해 가설을 검증할 것이다. 개인의 일상(Life)에 대한 기록(Log)이 합쳐진, 라이프로그(Life log)는 웨어러블 기기를 통해 자동적으로 축적되는 수면, 심박수, 활동량 관련 정보 등 따위의 것들을 뜻한다.

2. 본론

2.1 데이터 수집 및 EDA

데이터는 AI hub의 '치매 고위험군 웨어러블 라이프로그' 데이터셋을 사용하였으며 변수 별 설명은 표1(부록 첨부)과 같다[5]. Wearable device에서 수집한 수면, 심박수 등의 라이프로그 데이터와 정밀병리진단기반의 치매 위험도가 라벨링 되어 있다. 모두 같은 값으로 이루어진 '본수면여부'와 더불어 식별을 위한 ID, 결측값이 존재하는 열 등 분석에 불필요한 요소들을 제거해준 후 데이터셋의 사이즈는 (9327, 49)이다. CN(정상), MCI(경도인지장애), Dem(치매) 3가지 클래스로 이루어진 'DIAG_NM'은 치매 위험도가 라벨링 된 타겟값이다. 이 중 경도인지장애는 정상적인 노화현상으로 인한 인지능력 감퇴와 치매의 중간 단계를 의미한다. 그림1을 보면 타겟값의 분포가 CN(0, 정상)에 몰려 있는 불균형성을 띤다. 그림2의 상관관계를 시각화한 모습을 보았을 때, '활동량 - 소비 칼로리'에서 강한 상관관계, '수면 중 뒤척임 수 - 깊은 잠 점수'에서 강한 음의 상관관계 등 일부 변수 간 강한 상관관계를 보인다. 마지막 열에 위치한 타겟값 'DIAG_NM'의 경우 변수 간에 상관관계가 없거나 약한 상관관계를 보임을 알 수 있다. 그림3을 통해 전체 변수들의 분포를 확인할 수 있다. 이상치(Outlier)가 조금씩 있으나 이는 잘못 입력된 값이 아닌, 치매의 병리현상인 의도된 이상치로 판단하여 제거하지 않았다.

2.2 Modeling 및 성능비교

기계학습방법으로는 Decision Tree, Logistic Regression, kNN, Naïve Bayes, SVM, XGBoost, Random Forest 7가지를 Accuracy, F1score, AUC 3가지 성능평가지표를 사용해 비교 분석하였다. 불균형성을 가진 데이터의 Accuracy는 큰 신뢰를 가지지 못하므로 재현율과 정밀도의 조화평균 F1score(1)와 AUC의 중요도가 높다. Decision Tree, kNN, SVM모델은 Cross Validation을 통해 최적의 Hyper Parameter값을 찾아 성능을 개선시켰다. 표2에서 각 모델의 정확도, F1score, AUC를 확인할 수 있다. 세가지 지표는 모두 0에서 1의 범위를 가지며 1에 가까울수록 성능이 높다. 상위 모델 3가지는 XGBoost, Optimized SVM,

Optimized kNN이다. 그림4는 표2의 성능평가표를 시각화한 모습이다. 그림5는 가장 성능이 높았던 XGBoost의 ROC Curve이다. 3가지 클래스 이상의 다중분류문제에서는 각 클래스 별로 ROC Curve를 그려야 한다. 각 클래스 별 면적이 0.82, 0.81, 0.84로 편향되지 않은 예측성능을 보임을 알 수 있다.

$$Precision = \frac{True\ Positive}{True\ Positive + False\ Positive}$$

$$Recall = \frac{True\ Positive}{True\ Positive + False\ Negative}$$

$$F1score = \frac{2}{\frac{1}{Precision} + \frac{1}{Recall}} \dots (1)$$

Model	Accuracy	F1score	AUC
Decision Tree	0.71	0.71	0.70
Logistic Regression	0.67	0.67	0.63
Random Forest	0.79	0.79	0.73
Optimized kNN	0.79	0.79	0.77
kNN	0.76	0.76	0.74
GaussianNB	0.52	0.52	0.62
SVM	0.70	0.70	0.62
Optimized SVM	0.84	0.84	0.83
XGBoost	0.85	0.85	0.82

<표2. 모델 성능 비교표>

2.3 변수중요도 및 변수선택

앞서 언급하였듯이 그림2에서 몇몇 변수는 상관관계가 전혀 없는 변수들이 다수 존재함을 알 수 있다. 불필요한 다수의 변수는 계산을 복잡하게 만들고 성능 향상에 도움을 주지 못한다. 가장 우수한 성능을 보인 XGBoost 모델의 Feature Importance를 그림6에서 보면, '활동 목표달성 점수', '분당 낮은 심박동 수', '운동량 점수', '분당 평균 호흡 수', '매시간당 활동유지 점수', '활동 총 시간'이 상위 5개이며 활동성과 관계가 깊다. 변수 중요도를 내림차순으로 정렬한 후, 변수 0개부터 하나씩 변수를 추가하는 전진선택법으로 변수 추가에 따른 Cross Validation Score 변화를 측정하였다. 그림7에서 x축은 변수의 개수, y축은 5번의 교차 검증 점수 평균이다. 변수의 개수가 30개에서 0.85 최고 점수를 보인 후, 점수의 변화가 없다. 하위권의 경우 '수면 중 피부 온도 편차', '수면 잠복 점수' 등 활동성과 관계성이 떨어지는 변수들임을 알 수 있다.

3. 결론

3.1 분석 및 해석

본 프로젝트에서 각기 다른 분석기법을 사용하여 9가지 모델을 만들었고, 여러 모델 중 신뢰할 수 있는 성능을 가진 예측 모델을 만들었다[6]. 변수 중요도에서 상위권에 위치한 활동능력 수치에 따라 치매의 예측 정확도가 높아짐을 보아 서론에서 언급한 치매 진단 방법 중 ADL 저하와 긴밀한 관계가 있다고 판단된다. 이는 웨어러블 디바이스를 통해 수집한 데이터로그로 ADL 저하를 판단하여 치매의 예측이 가능함을 증명하였다. 본 프로젝트에서 제시한 치매 진단 모델을 웨어러블 디바이스에 접목하여 일반인들이 일

상생활 속 자연스럽게 쌓이는 라이프로그를 통해 데이터에 근거한 치매의 합리적 의심이 가능하다. 임상치의 진료 시간을 단축하고 조기 치매 발견을 통해 사회 경제적 비용의 감소를 기대할 수 있다.

3.2 프로젝트를 통해 얻은 교훈

기계학습은 여러 데이터를 한데 모아 데이터가 어떻게 작동하는지, 왜, 특정 결과의 확률, 그리고 이러한 결과의 미래 가능성을 알려준다. AI는 기계학습이 제공하는 권장사항에 조치를 취하는 것이다. 비유를 하자면, 바늘에 찔리면 뇌가 과거의 경험과 손가락의 따끔함으로부터 일어날 수 있는 일과 해야 할 일을 알려줘 우리는 바늘을 조심하게 된다. AI는 손가락이 바늘에 찔리지 않도록 조심하게 하는 기술력이다. 본 프로젝트에서 AI를 의학분야에 접목하여 문제를 해결하는 방안을 제시하였다. 이뿐만 아니라 다른 학우들의 프로젝트를 보며 AI는 의학분야 뿐 아니라 경영, 생명과학, 기계공학 등 다양한 분야에서 무궁무진하게 활용할 수 있다는 것을 볼 수 있었다. 그러기 위하여 우리는 특정 도메인에 전문적인 지식을 갖추어야 할 것이며, 데이터에 대한 이해와 고찰을 끊임없이 해야함을 배울 수 있었다.

참고문헌

- [1] "치매 명의 신경과 나덕렬 교수의 (진인사대천명GO!)와 함께 치매 바로 알고 예방하기! 치매의 원인과 종류, 예방법 총정리!", 삼성서울병원, 2014,
http://www.samsunghospital.com/home/healthInfo/content/contentView.do?CONT_SRC_ID=30848&CONT_SRC=HOMEPAGE&CONT_ID=7008&CONT_CLS_CD=001027
- [2] 최성혜, "치매의 임상적 진단", 2012-09, 대한당뇨병학회
- [3] American Psychiatric Association. Diagnostic and Statistical Manual of Mental Disorders DSM-IV-TR (Text Revision). 4th ed. Washington DC: American Psychiatric Association, 2000.
- [4] 양영순 외 7, "일상생활능력과 치매", 2012-05, Clinical Neuroscience Center, Seoul National University Bundang Hospital
- [5] "치매 고위험군 웨어러블 라이프로그 소개", AIHub, 2020,
<https://aihub.or.kr/aidata/30749>
- [6] 프로젝트 결과 코드,
<https://github.com/jiheon788/ajou-ml-Basic/blob/main/%ED%94%8C%EC%A0%9D.ipynb>


부록

NO	항목		NO	항목	
	영문명	한글명		영문명	한글명
1	email	이메일	34	sleep_bedtime_end	잠 종료시간


2	date	요약 날짜	35	sleep_bedtime_start	잠 시작시간
3	check	착용 여부 체크	36	sleep_breatj_average	분단 평균 호흡 수
4	nonwear	미착용 시간 체크	37	sleep_deep	깊은 수면 시간
5	activity_average_met	하루간 평균 MET	38	sleep_duration	잠 시간
6	activity_cal_active	하루간 활동 칼로리	39	sleep_efficiency	수면 효율
7	activity_cal_total	하루간 총 사용 칼로리	40	sleep_hr_5min	5 분 당 심박동 로그
8	activity_class_5min	하루간 5 분당 활동 로그	41	sleep_hr_average	분당 평균 심박동 수
9	activity_daily_movem ent	매일 움직인 거리	42	sleep_hr_lowest	분당 낮은 심박동 수
10	activity_day_end	활동 종료 시간	43	sleep_hypnogram_5mi n	수면 상태 로그
11	activity_day_start	활동 시작 시간	44	sleep_is_longest	본 수면 여부
12	activity_high	고강도 활동 시간	45	sleep_light	가벼운 수면 시간
13	activity_inactive	비활동 시간	46	sleep_midpoint_at_delt a	수면 중간점 시간 델타
14	activity_inactivity_ale rts	비활동 알람 횟수	47	sleep_midpoint_time	수면 중간점 시간
15	active_low	저강도 활동 시간	48	sleep_onset_latency	수면 잠복 시간
16	activity_medium	중강도 활동 시간	49	sleep_period_id	수면 식별 아이디
17	activity_met_1min	하루간 1 분 당 MET 로그	50	sleep_rem	렘수면 시간
18	activity_met_min_high	하루간 고강도 활동 MET	51	sleep_restless	뒤척임 비율
19	activity_met_min_ina ctive	하루간 비활동 MET	52	sleep_rmssd	평균 심박동변동
20	activity_met_min_low	하루간 저강도 활동 MET	53	sleep_rmssd_5min	5 분 당 심박동변동 로그
21	activity_met_min_me dium	하루간 중강도 활동 MET	54	sleep_score	수면 종합 점수
22	activity_non_wear	미착용 시간	55	sleep_score_alignment	수면 시기 점수
23	activity_rest	휴식 시간	56	sleep_score_deep	깊은 수면 점수
24	activity_score	활동 점수	57	sleep_score_disturban ces	수면 방해 점수
25	activity_score_meet_ daily_targets	활동 목표달성 점수	58	sleep_score_efficiency	수면 효율 점수

26	activity_score_move_every_hour	매 시간 당 활동유지 점수	59	sleep_score_latency	수면 잠복 점수
27	activity_score_recovery_time	회복시간 점수	60	sleep_score_rem	렘수면 점수
28	activity_score_stay_active	활동 유지 점수	61	sleep_score_total	수면 시간 기여 점수
29	activity_score_training_frequency	운동 빈도 점수	62	sleep_temperature_delta	피부 온도 편차
30	activity_score_training_volume	운동 빈도 점수	63	sleep_temperature_deviation	피부 온도 편차
31	activity_steps	매일 걸음 수	64	sleep_temperature_trend_deviation	피부 온도 경향 편차
32	activity_total	활동 총 시간(분)	65	timezone	시간 장소 정보
33	sleep_awake	깨 시간	66	sleep_total	수면 시간

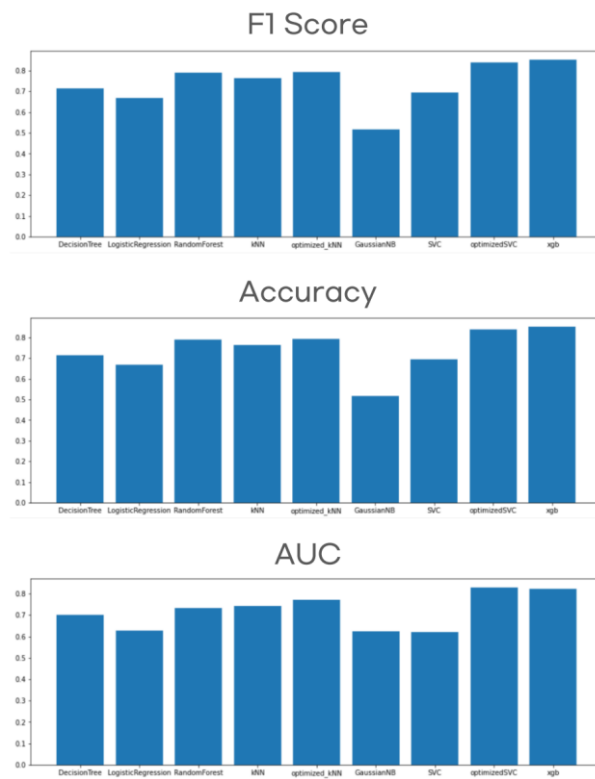
<표1. 데이터 변수 설명[5]>




<그림1. 타겟값 'DIAG_NM'의 분포>




<그림2. 상관관계 시각화>




<그림4. 모델 성능비교 그래프>



<그림5. XGBoost 기법을 사용한 모델의 변수 별 ROC Curve>



<그림6. XGBoost 기법을 사용한 모델의 Feature Importance>



<그림7. 변수 추가에 따른 교차검증 점수 측정 그래프>